

实验二: 系统调用

《操作系统》课程实验

●目录



● 实验目的

- ▶了解xv6系统调用的工作原理。
- >熟悉xv6通过系统调用给用户程序提供服务的机制。



请切换到syscall分支,实现两个系统调用:

- ① trace系统调用 int trace(int mask)
- mask:每一位对应一个系统调用,位的比特值指示是否需要追踪对应的系统调用。
 - ▶ 如调用trace(1 << SYS_fork),则代表只追踪系统调用fork。
 - ➤ 如调用trace(Oxffffffff),则代表追踪所有系统调用。
- ▶ 返回值:正常执行返回0,异常返回-1。

```
kernel > C syscall.h
     // System call numbers
      #define SYS fork
      #define SYS exit
      #define SYS wait
      #define SYS pipe
      #define SYS read
      #define SYS kill
      #define SYS exec
      #define SYS fstat 8
      #define SYS chdir
      #define SYS dup
      #define SYS getpid 11
      #define SYS sbrk 12
      #define SYS sleep 13
      #define SYS uptime 14
      #define SYS open 15
      #define SYS write 16
      #define SYS mknod 17
      #define SYS unlink 18
      #define SYS link 19
      #define SYS mkdir 20
      #define SYS close 21
```

● **实验原理** | 任务1: trace系统调用

- ① trace系统调用 int trace(int mask)
- ▶ 内核每处理完一次系统调用后 ,即系统调用返回前,若mask指示了该系统调用,则打印对应信息。打印格式: PID: sys_\$name(arg0) -return_value
- ➤ Trace 用户程序:通过 trace 系统调用设置需要跟踪的系统调用,然后启动另一个程序,显示该程序对指定系统调用的情况。

例1

3: sys_read(3) -> 1023

3: sys_read(3) -> 966

3: sys_read(3) -> 70

3: sys_read(3) -> 0

\$ trace 32 grep hello README

例2

```
$ trace 2147483647 grep hello README
4: sys_trace(2147483647) -> 0
4: sys_exec(12240) -> 3
4: sys_open(12240) -> 3
4: sys_read(3) -> 1023
4: sys_read(3) -> 966
4: sys_read(3) -> 70
4: sys_read(3) -> 0
4: sys_close(3) -> 0
```

例3

```
$ trace 2 usertests forkforkfork
usertests starting
test forkforkfork: 407: syscall fork -> 408
408: sys_fork(-1) -> 409
409: sys_fork(-1) -> 410
410: sys_fork(-1) -> 411
409: sys_fork(-1) -> 412
410: sys_fork(-1) -> 413
409: sys_fork(-1) -> 414
411: sys_fork(-1) -> 415
...
```

● 实验任务 | 任务2: sysinfo系统调用

- ② sysinfo系统调用 int sysinfo(struct sysinfo*)
- ▶ 功能:用于收集xv6运行的一些系统信息
- > 参数: 结构体 sysinfo的指针
 - > freemem: 当前剩余的内存字节数
 - ▶ nproc: 状态为UNUSED的进程个数
 - ▶ freefd: 当前进程可用文件描述符的数量,即尚未使用的文件描述符数量


```
1 struct sysinfo {
2  uint64 freemem;  // amount of free memory (bytes)
3  uint64 nproc;  // number of process
4  uint64 freefd;  // number of free file descriptor
5 };
```

当完成上述的两个实验后,在命令行输入make grade进行测试。如果通过测试,会显示如下内容:

```
== Test trace 32 grep ==
$ make gemu-gdb
trace 32 grep: OK (5.7s)
== Test trace all grep ==
$ make gemu-gdb
trace all grep: OK (1.0s)
== Test trace nothing ==
$ make qemu-gdb
trace nothing: OK (0.9s)
== Test trace children ==
$ make qemu-gdb
trace children: OK (16.8s)
== Test sysinfotest ==
$ make gemu-gdb
sysinfotest: OK (3.1s)
== Test time ==
time: OK
Score: 35/35
```

● 实验原理 | 系统调用

- 系统调用:操作系统为用户态进程与硬件设备进行交互提供了一组接口
 - 进程管理: 复制创建进程 fork、退出进程 exit、执行进程 exec 等
 - 进程间通信:管道 pipe
 - 虚存管理:改变进程内存空间大小 sbrk
 - 文件I/O操作:读 read、写 write、打开 open、关闭 close等
 - 文件系统: 改变当前目录 chdir、创建新目录 mkdir、创建设备文件 mknod等



```
user > C user.h
      struct stat;
      struct rtcdate;
      // system calls
      int fork(void);
      int exit(int) attribute ((noreturn));
      int wait(int*);
      int pipe(int*);
      int write(int, const void*, int);
      int read(int, void*, int);
      int close(int);
      int kill(int);
      int exec(char*, char**);
      int open(const char*, int);
      int mknod(const char*, short, short);
      int unlink(const char*);
      int fstat(int fd, struct stat*);
      int link(const char*, const char*);
      int mkdir(const char*);
      int chdir(const char*);
      int dup(int);
      int getpid(void);
      char* sbrk(int);
      int sleep(int);
      int uptime(void);
```



user/user.h

```
user > C user.h
       struct stat;
      struct rtcdate;
      int fork(void);
      int exit(int) __attribute__((noreturn));
      int wait(int*);
      int pipe(int*);
      int write(int, const void*, int);
      int read(int, void*, int);
       int close(int);
 11
 12
      int kill(int);
```

user/user.h xx系统调用函数



user/usys.pl

```
sub entry {
         my $name = shift;
         print ".global $name\n";
         print "${name}:\n";
         print " li a7, SYS ${name}\n";
         print " ecall\n";
         print " ret\n";
     entry("fork");
19
     entry("exit");
     entry("wait");
     entry("pipe");
     entry("read");
     entry("write");
     entry("close");
```

user/usys.S

```
.global write
28
     write:
      li a7, SYS_write
31
      ecall
      ret
```



usys.S

将系统调用号给寄存器 a7, 执行ecall指令触发 软中断,陷入内核态



kernel/trampoline.S

```
12
     .globl trampoline
13
     trampoline:
     .align 4
     .globl uservec
     uservec:
17
             # trap.c sets stvec to
              ld t1, 0(a0)
              csrw satp, t1
 79
              sfence.vma zero, zero
              # a0 is no longer val
              # table does not spec
              # jump to usertrap(),
              jr t0
```

user/user.h xx系统调用函数

usys.S

将系统调用号给寄存器 a7,执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S

Uservec段 上下文切换(PCB) 保存user进程数据 恢复kernel寄存器数据



kernel/trap.c

```
usertrap(void)
38 \ {
         int which dev = 0;
      if(r scause() == 8){
         // system call
         if(p->killed)
           exit(-1);
         // sepc points to the ecall instruction,
         // but we want to return to the next instruction.
         p->trapframe->epc += 4;
         // so don't enable until done with those registers
         intr_on();
         syscall();
       |} else if((which dev = devintr()) != 0){
        } else {
         printf("usertrap(): unexpected scause %p pid=%d\n";
         printf("
                             sepc=%p stval=%p\n", r sepc(),
         p->killed = 1;
        if(p->killed)
         exit(-1);
        // give up the CPU if this is a timer interrupt.
        if(which_dev == 2)
         yield();
       usertrapret();
```

user/user.h

xx系统调用函数

usys.S

将系统调用号给寄存器 a7,执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S

Uservec段 上下文切换(PCB) 保存user进程数据 恢复kernel寄存器数据

usertrap()

中断处理函数 检查是否为来自用户的 系统调用

kernel/syscall.c

```
syscall(void)
134 \ \ {
        int num:
        struct proc *p = myproc();
        num = p->trapframe->a7;
        if(num > 0 && num < NELEM(syscalls) && syscalls[num]) {</pre>
          p->trapframe->a0 = syscalls[num]();
        } else {
          printf("%d %s: unknown sys call %d\n",
                   p->pid, p->name, num);
          p->trapframe->a0 = -1;
```

user/user.h

xx系统调用函数

usys.S

将系统调用号给寄存器 a7, 执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S

Uservec段 上下文切换 (PCB) 保存user进程数据 恢复kernel寄存器数据

usertrap()

中断处理函数 检查是否为来自用户的 系统调用

syscall()

根据系统调用号,查询 表单找到对应的系统调 用函数

kernel/sysfile.c

```
uint64
     sys_write(void)
       struct file *f:
85
       int n;
       uint64 p;
87
       if(argfd(0, 0, &f) < 0 || argint(2, &n) < 0 || argaddr(1, &p) < 0)
         return -1;
       return filewrite(f, p, n);
```

user/user.h

xx系统调用函数

usys.S

将系统调用号给寄存器 a7, 执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S

Uservec段 上下文切换 (PCB) 保存user进程数据 恢复kernel寄存器数据

usertrap()

中断处理函数 检查是否为来自用户的 系统调用

syscall()

根据系统调用号,查询 表单找到对应的系统调 用函数

sys XXX()

kernel/syscall.c

user/user.h

xx系统调用函数

usys.S

将系统调用号给寄存器 a7,执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S

Uservec段 上下文切换(PCB) 保存user进程数据 恢复kernel寄存器数据

usertrap()

中断处理函数 检查是否为来自用户的 系统调用

syscall()

根据系统调用号,查询 表单找到对应的系统调 用函数

sys_XXX()



kernel/trap.c

```
usertrap(void)
38 \ {
         int which dev = 0;
        if(r scause() == 8){
         if(p->killed)
           exit(-1);
         // sepc points to the ecall instruction,
         // but we want to return to the next instruction.
         p->trapframe->epc += 4;
         // so don't enable until done with those registers
         intr_on();
         syscall():
       } else if((which dev = devintr()) != 0){
        } else +
         printf("usertrap(): unexpected scause %p pid=%d\n"
         printf("
                             sepc=%p stval=%p\n", r sepc(),
         p->killed = 1;
        if(p->killed)
         exit(-1);
        // give up the CPU if this is a time
        if(which_dev == 2)
         yield();
       usertrapret();
```

user/user.h

xx系统调用函数

usys.S

将系统调用号给寄存器 a7,执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S

Uservec段 上下文切换(PCB) 保存user进程数据 恢复kernel寄存器数据

usertrap()

中断处理函数 检查是否为来自用户的 系统调用

syscall()

根据系统调用号,查询 表单找到对应的系统调 用函数

sys_XXX()

kernel/trap.c

```
usertrapret(void)
 struct proc *p = myproc();
 // we're about to switch the destination of traps from
 // kerneltrap() to usertrap(), so turn off interrupts until
 // we're back in user space, where usertrap() is correct.
 intr_off();
 // send syscalls, interrupts, and exceptions to trampoline.S
 w stvec(TRAMPOLINE + (uservec - trampoline));
 // the process next re-enters the kernel.
 p->trapframe->kernel_satp = r_satp();
                                                // kernel page table
 p->trapframe->kernel sp = p->kstack + PGSIZE; // process's kernel stack
 p->trapframe->kernel trap = (uint64)usertrap;
                                                // hartid for cpuid()
 p->trapframe->kernel hartid = r tp();
```

```
uint64 satp = MAKE_SATP(p->pagetable);

// jump to trampoline.S at the top of memory, which
// switches to the user page table, restores user registers,
// and switches to user mode with sret.

uint64 fn = TRAMPOLINE + (userret - trampoline);
((void (*)(uint64,uint64))fn)(TRAPFRAME, satp);

// Saturdampoline);
// (void (*)(uint64,uint64))fn)(TRAPFRAME, satp);
```

user/user.h

xx系统调用函数

usys.S

将系统调用号给寄存器 a7,执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S

Uservec段 上下文切换 (PCB)

保存user进程数据 恢复kernel寄存器数据

usertrap()

中断处理函数检查是否为来自用户的

usertrapret()

将内核页表地址、内核栈指针、trap 处理函数地址写入trapframe, 计算出 要跳转到汇编代码的地址userret函数

syscall()

根据系统调用号,查询 表单找到对应的系统调 用函数

sys XXX()

内

核

态

实验原理 | 系统调用 (以write为例)

kernel/trampoline.S

```
# restore user a0, and save TRAPFRAME in sscratch
csrrw a0, sscratch, a0

# return to user mode and user pc.
# usertrapret() set up sstatus and sepc.

sret
```

user/user.h

xx系统调用函数

usys.S

将系统调用号给寄存器 a7,执行ecall指令触发 软中断,陷入内核态

Kernel/trampoline.S userret段

上下文切换 (PCB) 保存kernel进程数据 恢复user寄存器数据

usertrapret()

将内核页表地址、内核栈指针、trap 处理函数地址写入trapframe, 计算出 要跳转到汇编代码的地址userret函数

Kernel/trampoline.S Uservec段

1 7 --- | 11 | 7 | 7 | 7 | 7 |

保存user进程数据 恢复kernel寄存器数据

usertrap()

中断处理函数 检查是否为来自用户的 系统调用

syscall()

根据系统调用号,查询 表单找到对应的系统调 用函数


sys_XXX()



user/usys.S

```
.global write
write:
 li a7, SYS write
 ecall
ret
```

执行ret就结束了用户看到的系统调 用,返回至用户程序。



● 实验实现 | 具体流程

- ① trace系统调用 int trace(int mask)
- ➤ 本实验的内容及要求与MIT xv6 lab2不一样,请大家以指导书为准。
 - > Step1: 在做实验前,需切换到 syscall 分支进行实现:
 - ▶ 同步上游仓库: https://hitsz-lab.gitee.io/os-labs-2021/tools/#31

> 用户部分:

- Step2: 在Makefile中给 UPROGS 加 \$U/_trace
- > Step3: 在 user/user.h 加入函数声明
- > Step4: 在 user/usys.pl 加入用户系统调用名称

● 实验实现 | 具体流程

① trace系统调用 int trace(int mask)

> 内核部分:

- > Step5: 在 kernel/syscall.h 加入系统调用号SYS_trace
- > Step6: 在 kernel/sysproc.c 中添加 sys_trace()
- > Step7: 在 kernel/syscall.c 中加入对应的系统调用分发逻辑
- Step8: 开始实现 sys_trace() 对应的逻辑,同时该系统调用还需要修改其他函数的逻辑。

● 实验实现 | 实现提示

① trace系统调用 int trace(int mask)

- ▶ 进程启动 trace 后,如果 fork,子进程也应该开启 trace,并且继承父进程的mask。(这需要注意修改 kernel/proc.c 中 fork()的代码)
- ➤ 可以在 PCB (struct proc) 中添加成员 int mask, 这样我们可以记住trace告 知进程的 mask。 PCB定义于 kernel/proc.h
- ➤ 为了让每个系统调用都可以输出信息,我们应该在 kernel/syscall.c 中的 syscall()添加相应逻辑。
- ▶ 其他的系统调用实现可以参考, 详见 kernel/sysproc.c.



> 用户部分:

> Step1: 在 Makefile 中给 UPROGS 加 \$U/ sysinfotest

> Step2: 在 user/user.h 加入函数声明

> Step3: 在 user/usys.pl 加入用户系统调用名称

```
1 struct sysinfo {
2   uint64 freemem;  // amount of free memory (bytes)
3   uint64 nproc;  // number of process
4   uint64 freefd;  // number of free file descriptor
5 };
```

freemem: 当前剩余的内存 字节数

• nproc: **状态为UNUSED** 的进程个数

• freefd: 当前进程可用文件描述符的数量,即 尚未使用的文件描述符数量

```
/* 你需要在user/user.h添加如下定义 */
struct sysinfo; // 需要预先声明结构体,参考fstat的参数stat
int sysinfo(struct sysinfo *);
```

▶ 提示:

> sysinfo 需要在内核地址空间中填写结构体,然后将其复制到用户地址空间。可以参考fstat()(user/ls.c)、sys_fstat() (kernel/sysfile.c)、filestat()(kernel/file.c)中通过 copyout() 函数对该过程的实现。

```
filestat(struct file *f, uint64 addr)
                                                                                                                                                                                               // Copy stat information from inode.
char buf[512], *p;
                                                         uint64
                                                                                                                          struct proc *p = myproc();
                                                         sys fstat(void)
struct dirent de:
                                                                                                                          struct stat st;
struct stat st:
                                                                                                                                                                                                stati(struct inode *ip, struct stat *st)
                                                           struct file *f;
                                                                                                                           if(f->type == FD INODE || f->type == FD DEVICE){
                                                           uint64 st; // user pointer to struct stat
if((fd = open(path, 0)) < 0){
                                                                                                                            ilock(f->ip);
                                                                                                                                                                                                  st->dev = ip->dev:
                                                                                                                            stati(f->ip, &st);
 fprintf(2, "ls: cannot open %s\n", path);
                                                                                                                                                                                                  st->ino = ip->inum;
                                                           if(argfd(0, 0, &f) < 0 || argaddr(1, &st)
                                                                                                                           if(copyout(p->pagetable, addr, (char *)&st, sizeof(st)) < 0)</pre>
                                                                                                                                                                                                  st->type = ip->type;
                                                            return -1:
                                                                                                                                                                                                 st->nlink = ip->nlink:
                                                           return filestat(f, st);
if(fstat(fd, &st) < 0){
                                                                                                                                                                                        448
                                                                                                                                                                                                  st->size = ip->size;
 fprintf(2, "ls: cannot stat %s\n", path);
  close(fd);
```

▶ 提示:

▶ 计算剩余的内存空间的函数代码,最好写在文件 kernel/kalloc.c 里。 kmem.freelist是一个保存了当前空闲内存块的链表,因此只需要统计这个链表 的长度再乘以PGSIZE就可以得到空闲内存。

```
// Allocate one 4096-byte page of physical memory.
// Returns a pointer that the kernel can use.
// Returns 0 if the memory cannot be allocated.
void *
kalloc(void)

{
struct run *r;

acquire(&kmem.lock);
r = kmem.freelist;
if(r)
kmem.freelist = r->next;
release(&kmem.lock);

if(r)
memset((char*)r, 5, PGSIZE); // fill with junk
return (void*)r;
}
```

```
// Free the page of physical memory pointed at by v,
// which normally should have been returned by a
// call to kalloc(). (The exception is when
// initializing the allocator; see kinit above.)

kfree(void *pa)

free(void *pa)

free
```

▶ 提示:

▶ 计算空闲进程数量的函数代码,最好写在文件 kernel/proc.c 里。

proc->state字段保存了进程的当前状态,有UNUSED、SLEEPING、RUNNABLE、RUNNING、ZOMBIE五种状态

```
// Print a process listing to console. For debugging.
      // No lock to avoid wedging a stuck machine further.
      procdump(void)
       static char *states[] = {
        [SLEEPING] "sleep ",
        [RUNNABLE] "runble",
        [RUNNING]
                    "zombie"
        [ZOMBIE]
680
        struct proc *p;
        char *state:
        printf("\n");
        for(p = proc; p < &proc[NPROC]; p++){</pre>
          if(p->state == UNUSED)
          if(p->state >= 0 && p->state < NELEM(states) && states[p->state])
            state = states[p->state];
            state = "???";
          printf("%d %s %s", p->pid, state, p->name);
          printf("\n");
```

- ▶ 计算可用文件描述符数量的代码, 最好写在文件 kernel/proc.c 里。
- 文件描述符的值实际上就是 PCB 成员 ofile 的下标。

```
struct proc {
        struct spinlock lock;
        // p->lock must be held when using these:
        enum procstate state;
        struct proc *parent;
        void *chan;
                                     // If non-zero, sleeping on chan
                                     // If non-zero, have been killed
        int killed:
        int xstate;
                                     // Exit status to be returned to parent's wait
        int pid;
                                     // Process ID
        // these are private to the process, so p->lock need not be held.
97
                                    // Virtual address of kernel stack
        uint64 kstack;
        uint64 sz:
        pagetable t pagetable;
        struct trapframe *trapframe; // data page for trampoline.S
102
       struct context context:
       struct file *ofile[NOFILE];
104
       struct inode *cwd;
        char name[16];
```

● 实验实现 | 实现提示

② sysinfo系统调用 int sysinfo(struct sysinfo*)

- > 如何获取系统调用的参数?
 - > argint 获取整数,参数n代表定位第n个参数
 - > argptr 获取指针
 - > argstr 获取字符串起始地址


● 实验实现 | 实现提示

② sysinfo系统调用 int sysinfo(struct sysinfo*)

- ➤ 在添加上述三个函数后,可以在 kernel/defs.h 中声明,以便在其他文件中调用 这些函数。
- ➤ 查阅《xv6 book》 chapter1 和 chapter2 中相关的内容。

●实验提交

- ▶ 请务必注意查看<u>作业提交平台</u>,按时提交代码及报告
 - > 实验二提交截止时间: 下周二
 - ▶ 提交要求:
 - > kernel文件夹,包括kernel目录下所有修改后的文件
 - > user文件夹,包括user目录下所有修改后的文件
 - > Makefile文件
 - > 实验设计报告





同学们, 请开始实验吧!